Universidad Nacional del Centro de la Provincia de Buenos Aires

Facultad de Ciencias Exactas

Ingeniería de Sistemas

Materia: Fundamentos de la Ciencia de Datos

Grupo: 5

Integrantes:

Landolfi, Mateo Nicolás
landolfimateo@gmail.com

Bottini, Yaco
yacobotti2@gmail.com

Barletta, Ian Franco Pehuen
ibarletta@alumnos.exa.unicen.edu.ar

Introducción **3**
1. Análisis exploratorio de los datos **4**
1.1. Origen y contexto de los datos 4
1.2. Caracterización general del conjunto de datos 4
1.3. Descripción de los atributos 5
1.4. Valores faltantes 6
1.5. Distribución de las variables y detección de valores atípicos 7
1.5.1. Experiencia laboral y años programando 8
1.5.2. Remuneraciones 8
1.5.3. Cantidad de herramientas utilizadas 8
1.6. Particularidades y criterios para los análisis posteriores 9
2. Limpieza y Preparación de los Datos **9**
2.1. Reducción de dimensionalidad y eliminación de atributos redundantes 10
2.2. Tratamiento de inconsistencias y valores atípicos 11
2.3. Codificación de variables 11
3. Planteo de hipótesis **12**
3.1. Hipótesis univariada 12
3.2. Hipótesis bivariada 13
3.3. Hipótesis multivariada 13
4. Validación de las hipótesis **14**
4.1. Hipótesis univariada 14
4.2. Hipótesis bivariada 15
4.3. Hipótesis multivariada 15
4.4. Hipótesis a) 16
4.5. Hipótesis b) 17
4.6. Hipótesis c) 18
5. Conclusiones **20**
Referencias 22

Introducción

El presente trabajo tiene como objetivo realizar un análisis exploratorio y estadístico de los datos de la **Stack Overflow Developer Survey 2025**, una encuesta internacional que reúne respuestas de personas vinculadas al desarrollo de software y áreas relacionadas. A partir de este conjunto de datos, se busca identificar patrones, explorar relaciones entre variables y evaluar distintas hipótesis vinculadas con la experiencia profesional, las remuneraciones, la satisfacción laboral y el uso de herramientas de inteligencia artificial.

Para alcanzar estos objetivos, se llevará a cabo un proceso de exploración, caracterización y preparación de los datos, prestando especial atención a sus tipos de variables, distribuciones, valores faltantes y posibles inconsistencias. Posteriormente, se formularán y contrastarán hipótesis mediante técnicas estadísticas apropiadas para cada caso, fundamentando las decisiones metodológicas e interpretando los resultados obtenidos.

Finalmente, se buscará extraer conclusiones que permitan comprender mejor las tendencias observadas en las respuestas de los participantes, reconociendo tanto el valor de los resultados como las limitaciones del conjunto de datos. En particular, dado que las respuestas corresponden a una encuesta voluntaria, los hallazgos deberán interpretarse considerando que la muestra no necesariamente representa a la totalidad de las personas que trabajan en desarrollo de software.

1. Análisis exploratorio de los datos

Notebook: sección 1, “Análisis Exploratorio Inicial”.

1.1. Origen y contexto de los datos

Notebook: sección 1.1.

El conjunto de datos utilizado corresponde a la Stack Overflow Developer Survey 2025 [3], una encuesta anual realizada por Stack Overflow con el objetivo de recopilar información sobre las características profesionales de las personas vinculadas al desarrollo de software, las tecnologías que utilizan, sus condiciones laborales y sus opiniones sobre distintas herramientas y tendencias de la industria.

Según la documentación oficial, la encuesta de 2025 se realizó entre el 29 de mayo y el 23 de junio. La participación fue voluntaria y la difusión se efectuó principalmente mediante canales propios de Stack Overflow, como su sitio web, publicaciones, correos electrónicos y redes sociales. La documentación metodológica también advierte que este mecanismo de reclutamiento favorece la participación de usuarios más vinculados con la plataforma, por lo que los resultados no necesariamente representan a toda la población de desarrolladores. [1]

La información se obtuvo de los recursos públicos de la encuesta y se complementó con la documentación y los metadatos disponibles para interpretar los atributos de la base. Estos últimos resultan importantes para comprender el significado de las preguntas, los tipos de respuesta y las posibles restricciones de los valores registrados. [2]

1.2. Caracterización general del conjunto de datos

Notebook: sección 1.2.

La base analizada contiene **49.191 registros y 172 atributos**. Cada fila corresponde a una respuesta individual y cada columna representa una variable asociada con alguna de las preguntas de la encuesta.

La inspección inicial mediante las herramientas de Pandas permitió identificar la siguiente distribución de tipos de datos:

- 119 columnas de texto (Pandas las muestra como tipo object o str, según la versión): contienen principalmente respuestas textuales, categorías o datos que requieren una interpretación adicional.

- 52 columnas de tipo **float64**: almacenan valores numéricos con representación de punto flotante.
- 1 columna de tipo **int64**: almacena valores enteros.

La memoria estimada utilizada por el DataFrame es de aproximadamente 64,6 MB.

Esta clasificación describe cómo están almacenados los datos en Python, pero no determina por sí sola su naturaleza estadística. Por ejemplo, una variable numérica puede representar una cantidad, una categoría codificada o una escala de valoración. Por este motivo, la interpretación de los atributos se complementó con la revisión de sus nombres, las preguntas asociadas y los metadatos disponibles.

Cabe señalar que la documentación oficial informa 49.009 respuestas utilizadas en los resultados publicados. Como esta cifra difiere de los 49.191 registros de la base analizada, es necesario distinguir el conjunto de datos utilizado en este trabajo de las respuestas que Stack Overflow incluyó en sus estadísticas oficiales. La diferencia debe tenerse en cuenta al comparar los resultados propios con los publicados por la organización. [1]

1.3. Descripción de los atributos

Notebook: sección 1.3.

Debido a la cantidad de variables, los atributos se organizaron conceptualmente en grupos temáticos para facilitar su comprensión y orientar los análisis posteriores.

Entre los principales grupos se encuentran:

- **Perfil de los participantes**: edad (Age), país (Country), nivel educativo (EdLevel) y rama profesional (MainBranch).
- **Experiencia y trayectoria**: experiencia laboral (WorkExp), años programando (YearsCode), ocupación o rol profesional (DevType) y formas de aprendizaje (LearnCode).
- **Condiciones laborales**: situación de empleo (Employment), modalidad de trabajo (RemoteWork), tamaño de la organización (OrgSize) e industria (Industry).
- **Remuneración**: moneda declarada (Currency), compensación total informada (CompTotal) y remuneración anual convertida (ConvertedCompYearly).
- **Tecnologías y herramientas:** lenguajes de programación, bases de datos, plataformas, frameworks, entornos de desarrollo y otras herramientas utilizadas o deseadas.
- **Inteligencia artificial:** selección, uso, confianza, precisión percibida y opiniones sobre herramientas de IA y agentes.

- **Participación en Stack Overflow:** frecuencia de uso, interacción con la comunidad y preferencias de participación.
- **Satisfacción laboral**: satisfacción general (JobSat), aspectos asociados con el trabajo y consideración de cambiar de puesto o carrera.

La documentación de los atributos permitió distinguir variables con significados diferentes, incluso cuando se encuentran almacenadas con tipos de datos similares. En particular, WorkExp representa la experiencia laboral, mientras que YearsCode se refiere a los años programando; ambas pueden estar relacionadas, pero no son equivalentes.

Esta caracterización es relevante para seleccionar las variables que se utilizarán en las hipótesis y evitar interpretaciones incorrectas durante el análisis estadístico.

1.4. Valores faltantes

Notebook: sección 1.4.

Se examinó la presencia de valores faltantes mediante el conteo de registros nulos por columna y el cálculo de su proporción sobre el total de observaciones. Los resultados se organizaron en una tabla ordenada según el porcentaje de valores faltantes, con el propósito de identificar las variables más afectadas.

La revisión mostró que la ausencia de datos varía considerablemente entre atributos. Por ejemplo, EdLevel presenta 1.042 valores faltantes, equivalentes aproximadamente al 2,12 % de los registros, mientras que ConvertedCompYearly presenta 25.244 valores faltantes, alrededor del 51,32 %.

Estas diferencias deben interpretarse considerando el diseño de la encuesta. No todas las preguntas necesariamente fueron respondidas por todos los participantes: algunas respuestas pueden faltar porque una persona decidió no contestar, porque una pregunta no era aplicable a su situación o porque el flujo de la encuesta condicionaba su presentación.

Por lo tanto, los valores faltantes no se consideran automáticamente errores. Su tratamiento deberá definirse de acuerdo con el significado de cada variable y los requisitos de los análisis posteriores. En particular, la proporción de datos disponibles puede variar entre las hipótesis, por lo que se deberá informar el número de observaciones efectivamente utilizadas en cada análisis.

Según la clasificación vista en clase, la mayoría de los faltantes de la encuesta no son completamente al azar (MCAR): dependen del flujo del cuestionario y de quiénes lo abandonaron antes de terminarlo (MAR), y en el caso del salario también pueden deberse a que algunas personas prefieren no informarlo (MNAR). Por eso no imputamos estas variables y, en cada hipótesis,

trabajamos solo con quienes respondieron las preguntas involucradas, informando cuántas observaciones se usaron. Los resultados describen a ese subconjunto de encuestados, lo que se suma a las limitaciones de una encuesta voluntaria.

1.5. Distribución de las variables y detección de valores atípicos

Notebook: sección 1.5.

Para las variables categóricas se calcularon las frecuencias de las principales (MainBranch, Age, Employment, Country, RemoteWork, AIAcc y NewRole). La muestra está formada sobre todo por desarrolladores profesionales (76,2 %), jóvenes (el 52,3 % tiene menos de 35 años) y empleados (69,8 %). Estados Unidos concentra el 20,4 % de las respuestas, seguido por Alemania (8,5 %) e India (7,2 %). Esta composición refuerza el sesgo de selección de una encuesta voluntaria.

Para explorar el comportamiento de las variables numéricas se utilizaron estadísticas descriptivas y diagramas de caja (*boxplots*). Estos últimos permiten identificar observaciones alejadas del centro de la distribución mediante el rango intercuartílico.

La inspección visual de 53 variables numéricas permitió detectar posibles valores atípicos en variables relacionadas con la experiencia, las cantidades de herramientas utilizadas, las remuneraciones y distintas respuestas codificadas de la encuesta.

Sin embargo, se distinguió entre un valor estadísticamente extremo y un dato necesariamente incorrecto. La presencia de una observación fuera de los límites del boxplot constituye una señal para investigar, pero no justifica por sí sola su eliminación.

En las variables asociadas con opciones predefinidas o escalas delimitadas, como las familias TechEndorse_*, TechOppose_*, JobSatPoints_* y SO_Actions_*, se consideró que el criterio del rango intercuartílico no resulta suficiente para identificar errores. En estos casos, la validez debe evaluarse de acuerdo con el dominio permitido y el significado de las respuestas.

La revisión de valores atípicos se concentró, por lo tanto, en las variables cuantitativas cuyo comportamiento requiere una evaluación de plausibilidad y consistencia: WorkExp, YearsCode, ToolCountWork, ToolCountPersonal, CompTotal y ConvertedCompYearly.

1.5.1. Experiencia laboral y años programando

En WorkExp se identificaron valores extremos, incluidos registros con 80 años o más de experiencia y casos con valores de hasta 100 años. Algunos de estos registros presentan diferencias llamativas respecto del rango de edad declarado, por lo que se consideran casos que requieren revisión.

Se adoptó como criterio de investigación la coherencia entre la experiencia laboral declarada y la edad del participante. De manera complementaria, se analizarán los años programando (YearsCode) en relación con la edad, dado que declarar más años programando que años de vida constituye una inconsistencia lógica.

La inspección de estos casos busca distinguir respuestas plausibles de posibles errores de registro. Los valores extremos no se consideran inválidos únicamente por superar los límites estadísticos del boxplot.

1.5.2. Remuneraciones

Las variables CompTotal y ConvertedCompYearly requieren un análisis particular. La primera contiene la compensación total declarada en la moneda informada por el participante, mientras que la segunda representa la remuneración anual convertida a una moneda común.

En la inspección de los valores más altos de CompTotal aparecieron importes de magnitudes extraordinarias, incluidos valores del orden de 10^{74} y 10^{23}. Estas observaciones se consideran sospechosas y requieren examinar la moneda, el país y la remuneración convertida antes de determinar su validez.

La comparación entre monedas diferentes no puede realizarse directamente sobre los importes originales. Por este motivo, ConvertedCompYearly constituye una referencia más apropiada para estudiar las magnitudes de las remuneraciones en una escala común, aunque sus valores extremos también deben verificarse.

El objetivo de esta revisión es identificar posibles errores de carga o conversión sin descartar automáticamente remuneraciones elevadas que pudieran ser reales. Cualquier regla de limpieza deberá justificarse y documentarse antes de aplicarse.

1.5.3. Cantidad de herramientas utilizadas

También se detectaron valores extremadamente altos en ToolCountWork y ToolCountPersonal, con valores máximos observados de hasta 10.000 y 1.000, respectivamente.

Dado que estas variables representan cantidades de herramientas utilizadas en el ámbito laboral y personal, respectivamente, tales magnitudes resultan sospechosas

y requieren una inspección adicional. No obstante, su carácter extremo no demuestra por sí mismo que sean errores.

La revisión deberá determinar si estos valores corresponden a errores de registro, codificaciones particulares o respuestas que no pueden considerarse plausibles según la definición de las variables. Hasta contar con evidencia suficiente, no se establecerá un límite máximo arbitrario.

1.6. Particularidades y criterios para los análisis posteriores

La exploración inicial permitió identificar varios aspectos relevantes para las siguientes etapas del trabajo:

- La base contiene una combinación de variables cuantitativas, categóricas, ordinales y respuestas codificadas numéricamente, por lo que los métodos estadísticos deberán seleccionarse según la naturaleza de cada atributo.
- La proporción de valores faltantes varía entre preguntas y deberá tenerse en cuenta al definir las muestras utilizadas en cada análisis.
- Los valores extremos detectados mediante boxplots requieren una interpretación contextual; no deben eliminarse automáticamente por razones puramente estadísticas.
- Las variables de remuneración requieren especial atención a las monedas, las conversiones y las posibles diferencias de escala.
- La experiencia laboral y los años programando deberán revisarse considerando la edad declarada y las posibles inconsistencias lógicas.
- Las cantidades de herramientas requieren una evaluación de plausibilidad antes de establecer reglas de exclusión.

En esta etapa, el propósito principal fue caracterizar la base, identificar problemas potenciales y establecer criterios para las revisiones posteriores. Las modificaciones definitivas de los datos deberán documentarse por separado, indicando las reglas aplicadas, su justificación y la cantidad de observaciones afectadas.

2. Limpieza y Preparación de los Datos

Notebook: sección 2, “Limpieza de la Base de Datos”.

2.1. Reducción de dimensionalidad y eliminación de atributos redundantes

Notebook: sección 2.1.

La base analizada contenía originalmente 172 atributos y 49.191 observaciones. Para reducir la dimensionalidad hacia una estructura analítica manejable y libre de ruido estadístico sin sacrificar microdatos válidos, se procedió a descartar un conjunto significativo de variables que presentaban redundancia funcional, inconsistencias de origen o nula utilidad cuantitativa:

Campos de texto libre y respuestas no estructuradas: Se eliminaron las columnas abiertas asociadas a comentarios o justificaciones adicionales (sufijos _TEXT y Write, junto con preguntas abiertas como AIExplain y AIOpen). Las columnas _TEXT y Write tenían más del 95 % de valores faltantes (hasta un 99,46 %); AIExplain y AIOpen tenían alrededor de la mitad, pero, al igual que las anteriores, son texto libre con una elevada dispersión léxica que impide su aprovechamiento mediante técnicas estadísticas directas.

Entradas manuales de tecnologías no listadas (*Entry / *Entr): Se descartaron los campos en los que los encuestados podían tipear herramientas no contempladas en las opciones predeterminadas (tales como LanguagesHaveEntry, PlatformWantEntry o SOTagsWant Entry). Estos atributos mostraban una tasa de completitud residual (superior al 90–99% de valores nulos) y alta variabilidad tipográfica.

Preguntas introductorias o de filtro (gateways): Se suprimieron variables cuyo único fin en la encuesta era habilitar o deshabilitar secciones (como LanguageChoice, DatabaseChoice, PlatformChoice, WebframeChoice, DevEnvsChoice, AIModelsChoice, TechEndorseIntro y LearnCodeChoose). La información analítica relevante sobre el uso y preferencia de tecnologías se encuentra en las columnas de tecnologías trabajadas y deseadas (HaveWorkedWith y WantToWorkWith).

Remuneración en moneda local no estandarizada (CompTotal y Currency): La variable CompTotal mostraba el importe declarado en la divisa elegida por el participante (Currency). Debido al formato de campo numérico abierto sin validación estricta de entrada, esta columna registró distorsiones y magnitudes anómalas inverosímiles. Dado que las comparaciones entre monedas locales carecen de validez directa y que la base cuenta con la variable a escala en dólares anuales (ConvertedCompYearly), tanto CompTotal como Currency resultaban redundantes y fueron removidas.

Identificador administrativo (ResponseId): Se descartó la columna que almacena el identificador secuencial de registro generado por la plataforma, dado que no constituye un atributo de comportamiento ni una variable con significado estadístico.

2.2. Tratamiento de inconsistencias y valores atípicos

Notebook: sección 2.2.

A partir de los problemas detectados en el análisis exploratorio, se aplicaron filtros lógicos para garantizar la calidad de las observaciones numéricas:

Experiencia frente a Edad: se identificaron casos lógicamente imposibles, como registros con 100 años de experiencia laboral o con más experiencia que años de vida. Para cada rango de edad (Age) se tomó la edad máxima del rango y se calcularon dos límites: uno para la experiencia laboral (WorkExp), suponiendo que la vida laboral empieza a los 18 años, y otro para los años programando (YearsCode), suponiendo que se empieza a programar a los 5 años. Para "65 años o más" y "Prefiere no decirlo" se usaron límites fijos de 60 años de experiencia laboral y 65 años programando. Se eliminaron los 579 registros que superaban alguno de los dos límites. Como la encuesta pedía dejar el campo vacío cuando la experiencia laboral era 0, los valores nulos de WorkExp se completaron con 0. YearsCode no tenía esa indicación; sus nulos también se completaron con 0, pero esta variable no se usa en ninguna hipótesis.

Remuneración Estandarizada: Para corregir las magnitudes anómalas en las compensaciones, los filtros se aplicaron exclusivamente sobre la variable estandarizada en dólares (ConvertedCompYearly). Se estableció un límite inferior de $1.000 USD anuales: por debajo de ese valor está el 3 % de los salarios, con montos como 1, 2 o 10 dólares anuales que no son salarios creíbles, y se recortaron los salarios por encima del percentil 99. Los registros sin salario declarado (NaN) fueron conservados para no afectar el resto de los análisis descriptivos.

Volumen de Herramientas: Las variables referidas a la cantidad de herramientas utilizadas (ToolCountWork y ToolCountPersonal) registraron errores de carga con máximos de hasta 10.000. Se estableció un umbral máximo lógico de 100 herramientas (el doble del percentil 99, que es 50), descartando las observaciones que lo superaran y los valores nulos fueron imputados con cero, asumiendo que el campo vacío indica la no utilización de herramientas en dichos ámbitos.

2.3. Codificación de variables

Notebook: sección 2.3 (Age se codifica en la 2.2.1).

Para poder usar algunas variables en los modelos, se transformaron de la siguiente manera:

- **Age:** se convirtió en numérica tomando el límite superior de cada rango (24, 34, 44, 54 y 64 años, y 70 para "65 años o más"). "Prefiere no decirlo" quedó como valor faltante.
- **EdLevel:** se codificó de forma ordinal, de 1 (primaria) a 7 (título profesional o doctorado). La opción "Otro" quedó como valor faltante.
- **LearnCodeAI:** se creó la variable binaria LearnCodeAI_Bin, que vale 1 si la persona aprendió a usar herramientas de IA en el último año (por trabajo o por interés personal) y 0 si no. La variable original no se modificó.

3. Planteo de hipótesis

3.1. Hipótesis univariada

Hipótesis: la mayoría de los desarrolladores (más de la mitad) no consideró cambiar de carrera o de industria ni cambió de rol durante el último año.

Justificación: el desarrollo de software se percibe tradicionalmente como una profesión estable, con alta demanda laboral y buenas remuneraciones. Por eso esperamos que la mayor parte de los encuestados no esté pensando en abandonar su carrera. Al mismo tiempo, los despidos en empresas tecnológicas de los últimos años y la incertidumbre que genera la inteligencia artificial hacen interesante verificar si esa estabilidad se sigue observando.

Variable: NewRole (cualitativa nominal), que indica si la persona consideró un cambio de carrera o pasó a un nuevo rol en el último año. Definimos p como la proporción de personas que respondieron que no lo consideraron ni cambiaron, y planteamos H0: $p \leq 0,5$ y H1: $p > 0,5$.

3.2. Hipótesis bivariada

Hipótesis: los desarrolladores que trabajan bajo modalidad remota perciben una compensación anual en dólares (ConvertedCompYearly) significativamente mayor que quienes trabajan de forma presencial.

Justificación: el trabajo remoto elimina las barreras geográficas y permite acceder a empresas y mercados internacionales con escalas salariales más altas que las del mercado local. Por eso esperamos que la mediana salarial de quienes trabajan a distancia supere a la de quienes trabajan en una oficina.

Variables: RemoteWork (cualitativa nominal; las 5 opciones originales se agruparon en remoto, híbrido/flexible y presencial) y ConvertedCompYearly (cuantitativa continua). Planteamos H0: la mediana salarial es igual en las tres modalidades, y H1: al menos una modalidad tiene una mediana distinta.

3.3. Hipótesis multivariada

Hipótesis: el salario anual convertido a dólares (ConvertedCompYearly) está asociado con la edad (Age), la experiencia profesional (WorkExp), el aprendizaje de herramientas de IA durante el último año (LearnCodeAI) y el máximo nivel educativo alcanzado (EdLevel).

Justificación: quienes tienen más experiencia pueden acceder a puestos de mayor responsabilidad y mejor pagos, y la edad acompaña esa trayectoria. El aprendizaje de herramientas de IA refleja una actualización de conocimientos que puede abrir mejores oportunidades, y el nivel educativo puede facilitar el acceso a ciertos puestos.

Variables: ConvertedCompYearly como variable dependiente (cuantitativa continua) y Age, WorkExp, LearnCodeAI y EdLevel como explicativas. Planteamos H0: no existe una asociación significativa entre el salario y las variables explicativas, y H1: existe una asociación significativa con al menos una de ellas.

4. Validación de las hipótesis

4.1. Hipótesis univariada

Notebook: sección 3, "A. Hipótesis univariada".

Utilizamos un test Z para una proporción, unilateral a derecha y con α = 0,05. Es la técnica adecuada porque la variable se reduce a dos categorías y se compara la proporción observada con un valor fijo. Trabajamos con las 34.091 personas que respondieron la pregunta; descartamos 13.476 nulos: el 91,6 % de ellos no respondió ninguna pregunta posterior, es decir, abandonó la encuesta antes de llegar a esa parte. La condición $n \cdot p0 \geq 5$ se cumple ampliamente.

Solo el 45,73 % no consideró ni realizó un cambio de carrera. El estadístico fue $Z = -15{,}76$, con un p-valor unilateral prácticamente igual a 1, por lo que no se rechaza H0. Además, el intervalo de confianza del 95 % para la proporción, [45,20 % ; 46,26 %], queda completamente por debajo del 50 %.

La hipótesis no se confirma: ocurre lo contrario de lo planteado. El 54,3 % consideró un cambio o ya lo realizó: un 29,0 % lo consideró algo, un 14,5 % lo consideró mucho y un 10,7 % ya cambió. Como la encuesta es voluntaria, el resultado describe a quienes participaron y no necesariamente a todos los desarrolladores.

4.2. Hipótesis bivariada

Notebook: sección 3, "B. Hipótesis bivariada".

Trabajamos con las 20.132 personas que informaron su salario y su modalidad de trabajo. Como el salario no es normal en ninguna de las tres modalidades (Shapiro-Wilk, $p \approx 0$) y comparamos tres grupos independientes, usamos el test de Kruskal-Wallis ($\alpha = 0{,}05$), la alternativa no paramétrica al ANOVA.

Las medianas salariales fueron de USD 90.000 en la modalidad remota, USD 76.570 en la híbrida/flexible y USD 47.468,5 en la presencial. Kruskal-Wallis dio $H = 817{,}45$ con $p = 3{,}12 \times 10^{-178}$, por lo que se rechaza H0, con un tamaño de efecto $\eta^2 H = 0{,}041$, pequeño: aunque la diferencia de medianas es grande en dinero, dentro de cada modalidad hay mucha variación, sobre todo entre países. Las comparaciones de a pares con Mann-Whitney y corrección de Bonferroni mostraron que las tres modalidades difieren entre sí, y el test unilateral confirmó que el salario remoto es mayor que el presencial ($p = 9{,}17 \times 10^{-155}$).

Como el salario depende mucho del país, repetimos la comparación dentro de Estados Unidos (4.525 respuestas) y se mantuvo el mismo orden: USD 160.272 en la modalidad remota, USD 143.050 en la híbrida y USD 105.414 en la presencial ($p = 1{,}84 \times 10^{-57}$).

Conclusión: la hipótesis se confirma. Quienes trabajan de forma remota perciben salarios mayores que quienes trabajan de forma presencial: casi el doble en la mediana global y un 52 % más dentro de Estados Unidos. Al tratarse de datos observacionales, el resultado muestra una asociación y no una causa; por ejemplo, los puestos remotos podrían corresponder a perfiles más senior.

4.3. Hipótesis multivariada

Notebook: sección 3, "C. Hipótesis multivariada".

Elegimos la regresión lineal múltiple porque la variable a explicar, el salario, es cuantitativa y queremos evaluar el efecto de varias variables al mismo tiempo, controlando unas por otras. Usamos un modelo de regresión lineal múltiple estimado por mínimos cuadrados ordinarios (OLS), con las 22.462 personas que informaron su salario y no tenían nulos en las variables del modelo. Usamos el logaritmo del salario como variable dependiente: así cada coeficiente se interpreta como un cambio porcentual, que es la forma habitual de modelar salarios, y los salarios más altos no dominan el ajuste. El logaritmo

no elimina la asimetría, sino que la invierte (pasa de 1,33 a −1,34 por los salarios más bajos), lo que después se ve en la cola izquierda de los residuos. Excluimos la edad porque está muy correlacionada con la experiencia (ρ de Spearman = 0,86), y mantenerlas juntas generaría multicolinealidad; la edad también se asocia con el salario (ρ = 0,39, p ≈ 0). El modelo final fue $\log(\text{Salario}) = \beta_0 + \beta_1 \cdot \text{WorkExp} + \beta_2 \cdot \text{LearnCodeAI_Bin} + \beta_3 \cdot \text{EdLevel} + \varepsilon$.

El test F global fue significativo (F = 1.338,81; p ≈ 0), por lo que se rechaza H0. Los tres coeficientes son positivos y significativos: cada año de experiencia se asocia con un salario 4,0 % mayor, haber aprendido herramientas de IA con uno 3,9 % mayor (p = 0,0075) y cada nivel educativo adicional con uno 10,2 % mayor. El modelo explica el 15,2 % de la variabilidad del salario (R^2 = 0,152).

En cuanto a los supuestos, los residuos no son normales (Shapiro-Wilk con p ≈ 0 y una cola izquierda larga en el QQ-plot), aunque con más de 22.000 observaciones los tests siguen siendo aproximadamente válidos. La varianza de los residuos no es constante, así que recalculamos los p-valores con errores estándar robustos (HC3), y los tres coeficientes siguieron siendo significativos. Los VIF cercanos a 1 indican que no hay multicolinealidad.

Conclusión: la hipótesis se confirma. La experiencia, el aprendizaje de IA y el nivel educativo se asocian con un mayor salario, aunque el modelo explica una parte chica de su variabilidad. La principal variable ausente es el país de residencia, que no forma parte de la hipótesis: por sí solo, el país explica el 43 % de la variabilidad del logaritmo del salario.

4.4. Hipótesis a)

Hipótesis a): los desarrolladores que respondieron la encuesta de Argentina tienen un salario 3 veces mayor al Salario Mínimo, Vital y Móvil (SMVM).

Notebook: sección 4, "a) Los desarrolladores que respondieron la encuesta de Argentina…".

Interpretamos la hipótesis como que la mediana del salario anual de los desarrolladores de Argentina es al menos 3 veces el SMVM anual. La encuesta se hizo entre el 29 de mayo y el 23 de junio de 2025, cuando el SMVM era de $313.400 mensuales (Resolución 5/2025) [4]. Como el salario de la encuesta es anual e incluye bonos [5], anualizamos el SMVM con 13 sueldos (con aguinaldo). Para pasarlo a dólares usamos el tipo de cambio que aplicó Stack Overflow, que obtuvimos de los propios datos al dividir el salario en pesos por el salario convertido: 1.172,26 pesos por dólar. Así, el SMVM anual equivale a USD 3.476 y el umbral, a USD 10.427.

Hay 145 desarrolladores de Argentina con salario informado, con una mediana de USD 42.653. Como los salarios no son normales (Shapiro-Wilk, $p = 1{,}5 \times 10^{-5}$), usamos el test de Wilcoxon para una muestra, unilateral (H0: mediana ≤ umbral; H1: mediana > umbral). El p-valor fue $5{,}25 \times 10^{-23}$, por lo que se rechaza H0. Como Wilcoxon supone una distribución simétrica y los salarios son asimétricos, también aplicamos la prueba del signo, que no necesita ese supuesto: mostró que 126 de los 145 salarios (86,9 %) superan el umbral ($p = 7{,}34 \times 10^{-21}$). Sin aguinaldo, el umbral baja a USD 9.625 y la conclusión no cambia.

Conclusión: la hipótesis se confirma: la mediana del salario equivale a 12,3 veces el SMVM. Como limitación, la muestra es chica y voluntaria, y quienes responden una encuesta en inglés de Stack Overflow pueden tener más acceso a trabajos pagados en dólares. Además, el resultado depende del tipo de cambio usado.

4.5. Hipótesis b)

Hipótesis b): los años de experiencia profesional influyen en la confianza en la precisión de las herramientas de IA.

Notebook: sección 4, "b) Los años de experiencia profesional influyen…".

Usamos WorkExp (años de experiencia, cuantitativa) y AIAcc (confianza en la precisión de la IA, ordinal con 5 niveles), con las 31.993 personas que respondieron ambas preguntas. En la limpieza, los valores vacíos de WorkExp se completaron con 0, porque la encuesta pedía dejar el campo vacío cuando la experiencia era 0. Planteamos H0: la mediana de experiencia es igual en todos los niveles de confianza, y H1: al menos un nivel tiene una mediana distinta.

Como WorkExp no es normal en ningún grupo (Shapiro-Wilk, $p \approx 0$), usamos el test de Kruskal-Wallis. Dio $H = 32{,}00$ con $p = 1{,}92 \times 10^{-6}$, por lo que se rechaza H0 en términos estadísticos. Sin embargo, el tamaño del efecto es $\eta^2 H = 0{,}0009$, despreciable. Las comparaciones de a pares con Bonferroni mostraron que solo el grupo que confía mucho en la IA difiere del resto, con una mediana de 9 años de experiencia contra 10 en los demás. La correlación de Spearman fue $\rho = -0{,}021$: a más experiencia hay levemente menos confianza, pero la relación es prácticamente nula.

Conclusión: la hipótesis no se confirma en términos prácticos. Las diferencias son estadísticamente significativas solo por el gran tamaño de la muestra; la

experiencia profesional casi no se relaciona con la confianza en la precisión de la IA.

4.6. Hipótesis c)

Hipótesis c): *los distintos niveles de satisfacción en los distintos aspectos del trabajo actual están relacionados con la consideración de un cambio de rol o de carrera.*

Notebook: sección 4, "c) Los distintos niveles de satisfacción…".

Interpretación de las variables. Las columnas JobSatPoints_* no miden la satisfacción con cada aspecto, sino un ranking: cada persona ordenó 15 aspectos de su trabajo actual según cuánto contribuyen a su satisfacción, del 1 (más importante) al 15. Verificamos que el 100 % de las filas cumple esa estructura. Por eso separamos la hipótesis en dos preguntas: si el nivel de satisfacción general (JobSat, escala de 0 a 10) se relaciona con la consideración de un cambio (NewRole), y si la importancia que se le da a cada aspecto se relaciona con esa consideración. Finalmente evaluamos todas las variables en conjunto.

Decisiones previas. Excluimos JobSatPoints_15 (opción "Otro"), que el 96,2 % ubicó en el último lugar. De NewRole usamos los tres grupos que expresan un grado de consideración (no consideró, consideró algo, consideró mucho) y excluimos a quienes ya cambiaron, porque su trabajo actual es el nuevo. Los nulos se eliminaron solo para este análisis.

Paso 1: satisfacción general. El test de Shapiro-Wilk rechazó la normalidad de JobSat ($p \approx 0$), y además se trata de una escala ordinal, por lo que usamos Kruskal-Wallis en lugar de ANOVA. Con 22.800 observaciones, el test fue significativo ($H = 2.879{,}14$; $p \approx 0$) con un tamaño de efecto $\eta^2 H = 0{,}126$, moderado. Las comparaciones de a pares con Mann-Whitney y corrección de Bonferroni mostraron que los tres grupos difieren entre sí: la mediana de satisfacción es 8 en quienes no consideraron un cambio, 7 en quienes lo consideraron algo y 6 en quienes lo consideraron mucho.

Paso 2: importancia de cada aspecto. Aplicamos Kruskal-Wallis a cada uno de los 14 aspectos (21.409 observaciones), con corrección de Bonferroni ($\alpha = 0{,}05 / 14 \approx 0{,}0036$). Seis aspectos resultaron significativos (mentores expertos, orientar a otros, autonomía y confianza, problemas complejos, remuneración y control sobre la calidad), pero todos con un efecto despreciable: el mayor $\eta^2 H$ fue 0,0025. Las

diferencias en la posición media son de menos de un lugar del ranking, y los tres grupos ordenan los aspectos casi igual.

Paso 3: análisis multivariado. Ajustamos una regresión logística para predecir si la persona consideró un cambio (sí/no) a partir de los 14 rankings y JobSat (20.643 observaciones, 70 % para entrenamiento y 30 % para prueba, variables estandarizadas). Comparamos tres modelos con un modelo trivial que siempre predice la clase más frecuente:

Modelo	Accuracy en prueba
Solo aspectos	53,2 %
Solo satisfacción general	64,8 %
Aspectos + satisfacción general	65,2 %
Trivial (clase más frecuente)	51,7 %

Los aspectos solos superan al modelo trivial por apenas 1,5 puntos, y agregarlos a JobSat suma menos de medio punto. El coeficiente de JobSat (−0,74) es mucho mayor en valor absoluto que el de cualquier aspecto (todos menores a 0,1); su signo indica que a mayor satisfacción, menor probabilidad de considerar un cambio.

Conclusión. La hipótesis se confirma parcialmente. El nivel de satisfacción general sí se relaciona con la consideración de un cambio de carrera: quienes están menos satisfechos lo consideran más. En cambio, la importancia relativa que se le da a cada aspecto del trabajo no muestra una relación relevante: algunas diferencias son estadísticamente significativas por el tamaño de la muestra, pero su efecto es despreciable y casi no mejoran la predicción. Como limitación, la encuesta no mide la satisfacción con cada aspecto por separado, por lo que no es posible saber si alguien está insatisfecho con un aspecto puntual.

5. Conclusiones

Hipótesis	Técnica	Resultado
Univariada: más de la mitad no consideró cambiar de carrera	Test Z para una proporción	No se confirma (45,7 %)
Bivariada: quienes trabajan en forma remota ganan más que quienes trabajan en forma presencial	Kruskal-Wallis y Mann-Whitney	Se confirma
Multivariada: la experiencia, la IA y la educación se asocian con el salario	Regresión lineal múltiple	Se confirma ($R^2 = 0,15$)
a) En Argentina, el salario es al menos 3 veces el SMVM	Wilcoxon y prueba del signo	Se confirma (12,3 veces)
b) La experiencia influye en la confianza en la IA	Kruskal-Wallis y Spearman	No se confirma en la práctica
c) La satisfacción se relaciona con considerar un cambio de carrera	Kruskal-Wallis y regresión logística	Se confirma en parte

Salario. El salario de los desarrolladores se asocia con la modalidad de trabajo, la experiencia, el nivel educativo y, en menor medida, con haber aprendido herramientas de IA. Aun así, estas variables explican una parte chica de su variabilidad: el país de residencia es el factor que más pesa en un salario expresado en dólares. En Argentina, los encuestados ganan muy por encima del salario mínimo, aunque esa muestra es chica y probablemente incluye a muchas personas que trabajan para el exterior.

Satisfacción y cambio de carrera. Más de la mitad de los encuestados consideró cambiar de carrera o ya lo hizo durante el último año. Quienes están menos satisfechos con su trabajo son los que más lo consideran, mientras que los aspectos del trabajo que cada persona valora casi no cambian entre quienes piensan en irse y quienes no.

Inteligencia artificial. La experiencia profesional casi no se relaciona con la confianza en la precisión de las herramientas de IA: desarrolladores con poca y con mucha experiencia confían, o desconfían, de manera muy parecida.

Aprendizaje metodológico. Con muestras de decenas de miles de respuestas, casi cualquier diferencia resulta estadísticamente significativa. Por eso fue clave complementar los p-valores con el tamaño del efecto, para distinguir las diferencias relevantes de las que solo son detectables.

Limitaciones. La encuesta es voluntaria y se difundió por los canales de Stack Overflow, así que describe sobre todo a sus usuarios y no a todos los desarrolladores. Los salarios son declarados por los propios encuestados y están convertidos a dólares. Además, como los datos son observacionales, los resultados muestran asociaciones y no relaciones de causa y efecto.

Referencias

[1] Stack Overflow. *2025 Developer Survey — Methodology*. https://survey.stackoverflow.co/2025/methodology

[2] Stack Exchange. *Stack Overflow Developer Survey — Official Repository*. https://github.com/StackExchange/Survey

[3] Stack Overflow. *2025 Developer Survey*. https://survey.stackoverflow.co/2025/

[4] Consejo Nacional del Empleo, la Productividad y el Salario Mínimo, Vital y Móvil. *Resolución 5/2025* (RESOL-2025-5-APN-CNEPYSMVYM#MCH). Boletín Oficial de la República Argentina, 9 de mayo de 2025.

[5] Stack Exchange. *Stack Overflow Developer Survey 2025 — Schema (metadatos).* https://media.githubusercontent.com/media/StackExchange/Survey/refs/heads/main/packages/archive/2025/schema.csv